

多地域臨床試験における地域プーリングのための効果修飾 因子類似性の定量化

Quantifying Effect Modifier Similarity for Regional Pooling in Multi-Regional Clinical Trials

要旨 (Abstract)

ICH E17 ガイドラインは、多地域臨床試験 (MRCT) における地域プーリングを効果修飾因子 (EM) 分布の類似性に基づいて行うことを推奨しているが、そのような類似性を定量化する具体的な方法論は示されていない。既存のアプローチは位置差 (標準化平均差; SMD) に焦点を当てるか、解釈可能なスケールを欠いている (Kolmogorov-Smirnov 統計量)。本論文では、**正規化累積分布間面積** (normalized Area Between Cumulative Distributions; nABCD) を提案する。nABCD は、2 つの分布間の Wasserstein-1 距離をプールされた四分位範囲の 2 倍で除したものと定義される。SMD とは異なり、nABCD は分散、形状、歪度の差を捕捉する——非線形の効果修飾を通じて治療効果異質性を駆動しうる分布的特徴を余すことなく検出する。

CATE 感度に関する事前エビデンスが利用可能な場合、nABCD は**臨床較正** (clinical calibration) を可能にする：地域間の最大潜在的治療効果差 ($\Delta_{\max}$) は、nABCD、プール IQR、および CATE 感度パラメータの関数として表現でき、ブートストラップ信頼区間が推定の不確実性を定量化する。

8 つのシナリオにわたるシミュレーション研究は、MRCT 地域サブグループに典型的なサンプルサイズにおいて、パーセンタイルブートストラップ推定量の十分なバイアスおよびカバレッジを実証した。IST-3 (Third International Stroke Trial; $n = 3,035$, 8 ヶ国) への適用は、仮想的血栓溶解薬 MRCT の前向き計画演習として構成し、nABCD が SMD では検出できない分布差を捕捉すること、および臨床較正が CATE 感度に応じて著しく異なる結論をもたらすことを実証した：NIHSS の分布差 (nABCD = 0.240) は実質的な潜在的治療効果異質性 ($\Delta_{\max} = 5.02\%$ pt) に変換され、年齢の分布差は、より大きな分布的隔たり (nABCD = 0.285) にもかかわらず、限定的な臨床的影響 ($\Delta_{\max} = 0.47\%$ pt) に留まった。

nABCD フレームワークは、原理に基づく分布比較指標とオプションな臨床較正パスウェイを提供することにより、ICH E17 実装における方法論的ギャップを埋め、エビデンスに基づくプーリング決定を支援する。

キーワード: 多地域臨床試験、ICH E17、効果修飾因子、Wasserstein 距離、地域プーリング、分布類似性

略語一覧

Table1: 略語一覧

略語	英語	日本語
ABCD	Area Between Cumulative Distributions	累積分布間面積
CATE	Conditional Average Treatment Effect	条件付き平均治療効果
CDF	Cumulative Distribution Function	累積分布関数
CI	Confidence Interval	信頼区間
EM	Effect Modifier	効果修飾因子
EU	European Union	欧州連合
ICH	International Council for Harmonisation	医薬品規制調和国際会議
IPD	Individual Patient Data	個別患者データ
IQR	Interquartile Range	四分位範囲
IST-3	Third International Stroke Trial	第3回国際脳卒中試験
KL	Kullback–Leibler	カルバック–ライブラー
KS	Kolmogorov–Smirnov	コルモゴロフ–スミルノフ
MRCT	Multi-Regional Clinical Trial	多地域臨床試験
nABCD	Normalized Area Between Cumulative Distributions	正規化 ABCD
NIHSS	National Institutes of Health Stroke Scale	NIH 脳卒中スケール
NMPA	National Medical Products Administration	国家薬品监督管理局
OHS	Oxford Handicap Scale	オックスフォード障害スケール
SMD	Standardized Mean Difference	標準化平均差

1 序論 (Introduction)

多地域臨床試験 (MRCT) は、単一のプロトコルのもとで複数の国または規制地域にわたって実施される試験であり、グローバル医薬品開発の標準パラダイムとなっている (Chen et al. 2010; Quan et al. 2010)。このアプローチは、タイムラインの加速、より広い一般化可能性、世界中の患者への新規治療への早期アクセスという実質的な利点を提供する。2017 年に採択された ICH E17 ガイドラインは、MRCT の計画・設計の原則を確立し、治療効果がターゲット集団全体に一般化可能であるという中心的な仮定を置いた (ICH E17)。

治療成果における地域的一貫性を評価する能力を高めるための主要戦略が、**地域プーリングアプローチ**であり、類似の患者特性を持つ地域を解析のためにグループ化する (ICH E17)。ICH E17 ガイドラインは、プーリング決定を効果修飾因子 (EM) 分布の類似性に基づいて行うことを明示的に推奨している：

「疾患および/または研究対象薬物に関連する内因性および/または外因性因子に関して、被験者が**十分に類似している**と考えられる場合、地域はランダム化および/または解析のためにプーリングしてもよい。」 (ICH E17, Section 2.2.5)

効果修飾因子 (effect modifier) とは、年齢、疾患重症度、遺伝子マーカーなどのベースライン患者特性であり、治療効果がサブグループ間で異なるものをいう。例えば、若年患者が高齢患者より治療に良好に反応する場合、年齢は効果修飾因子である。このような異質性が存在する場合、たとえ薬剤が個人レベルで同一に作用しても、異なる患者構成を持つ地域は異なる平均治療効果を観察しうる。若年患者が多い地域は高齢患者が多い地域より大きな効果を示すが、これは薬剤の作用が異なるからではなく、**患者ミックスが異なるため**である。この基本的な関係は、EM 分布の類似性が地域プーリングの妥当性にとってなぜ重要であるかを強調している。

EM 分布の類似性の規制上の重要性にもかかわらず、現在の実務には標準化された定量的方法論が欠如している。ICH E17 ガイドラインは分布が「十分に類似している」かどうかを判断するための特定の指標、閾値、統計的手順を提供していない。最近の規制ガイダンスはこのギャップを指摘している。Song ら (2025) は、中国 NMPA の観点から ICH E17 実装における定量的ツールなしにプーリング基準を運用する課題を指摘し、Long ら (2025) は ICH E17 に基づく一貫性評価の基本的考慮事項を議論している。

現行の分布類似性評価アプローチには重大な限界がある (Table 2)。標準化平均差 (SMD) は、ベースライン共変量比較に広く用いられている (Austin 2011) が、分散や分布形状の差を根本的に検出できない——まさに効果修飾を通じて治療効果異質性を駆動しうるタイプの差異である。

Table2: 分布類似性評価における現行アプローチの限界

方法	限界
目視検査	主観的、再現性がない

方法	限界
標準化平均差 (SMD)	位置のみ捕捉、スケールと形状を無視
Kolmogorov-Smirnov 統計量	意思決定のための解釈可能なスケールを持たない

本論文は、この方法論的ギャップに対処するため、地域間の EM 分布を比較するための指標である正規化累積分布間面積 (nABCD) と、分布差を治療成果スケール上の潜在的治療効果異質性に変換する臨床較正フレームワークを提案する。本研究の研究課題は：

地域間の分布類似性をスケールフリーな方法で推定し、その推定値を潜在的治療効果異質性に関する臨床的に解釈可能な情報に変換するにはどうすればよいか？

重点は**推定と臨床的解釈**にあり、仮説検定ではない。二値的な受容/棄却ルールではなく、審議に情報を提供する定量的ツールを規制科学者に提供することを目指す。この設計哲学は、プーリング決定が閾値の機械的適用ではなく文脈的判断を必要とするという ICH E17 の原則を反映している。

nABCD 指標は、2 つの累積分布関数間の総面積を、プールされた四分位範囲で正規化して、スケールフリーな解釈を実現する。nABCD フレームワークの貢献は 4 つである：

1. **完全な分布比較:** Wasserstein-1 距離は位置、スケール、形状の差を同時に捕捉する (Panaretos & Zemel 2019)。
2. **スケールフリーな推定:** IQR による正規化は無次元の指標を与え、異なるスケールで測定された EM 間の比較を可能にする。ブートストラップ信頼区間が推定の不確実性を定量化する。
3. **臨床較正:** 異質性バウンド (Proposition 2) を通じて、nABCD 推定値を各 EM の臨床的文脈に特異的な潜在的治療効果差 ($\Delta_{\max}$) に変換でき、主要評価項目スケール上で表現できる (Pearl & Bareinboim 2011)。
4. **感度分析:** 較正が CATE 感度パラメータ L (不確実でありうる) に依存するため、フレームワークは L にわたる感度分析を自然に収容し、単一の二値検定よりも豊富なエビデンス基盤を意思決定に提供する。

本研究は連続型の効果修飾因子に焦点を当て、これに対して Wasserstein 距離が自然かつ理論的に根拠のある分布的非類似性の指標を提供する。カテゴリカルまたは混合型の効果修飾因子 (例：遺伝子型、人種、先行治療歴) は代替的な距離指標を必要とし、本研究の範囲外である。

以下の構成で述べる。第 2 節で方法論的フレームワーク、第 3 節で包括的なシミュレーション研究、第 4 節で IST-3 脳卒中試験の公開 IPD を用いた仮想的血栓溶解薬 MRCT の前向き計画演習としてのフレームワーク実証、第 5 節で含意・限界・今後の方向を議論する。

2 方法 (Methods)

2.1 nABCD 指標

効果修飾因子 (EM) は、治療効果がサブグループ間で変動するベースライン患者特性である。条件付き平均治療効果 (CATE) を $\tau(x) = E[Y(1) - Y(0) \mid X = x]$ と表記すると、 X は EM である。この関数が非定数であるとき、地域 r で観察される平均治療効果は、その地域における EM の分布 F_r に依存する：

$$\bar{\tau}_r = \int \tau(x) dF_r(x) \quad (1)$$

分布差と治療効果異質性の関係を定式化するため、CATE 関数が Lipschitz 定数 L で有界であるとする。地域平均治療効果の差は以下のようにバウンドされる：

$$|\bar{\tau}_1 - \bar{\tau}_2| \leq L \cdot W_1(F_1, F_2) \quad (2)$$

ここで $W_1(F_1, F_2)$ は地域 1 と地域 2 における EM 分布間の Wasserstein-1 距離を表す。

Wasserstein-1 距離 (Earth Mover's Distance と呼ばれる) は、2 つの累積分布関数 F と G の間で以下のように定義される (Villani 2009)：

$$W_1(F, G) = \int_{-\infty}^{\infty} |F(x) - G(x)| dx \quad (3)$$

幾何学的に、これは 2 つの CDF で囲まれた総面積に等しい (図 1 参照)。SMD とは異なり、Wasserstein 距離は分散、歪度、その他の分布的特徴の変化に応答する (Panaretos & Zemel 2019)。代替的な距離指標よりも W_1 を選択する理由は、Kantorovich–Rubinstein 双対定理 (Villani 2009) にあり、これが分布距離と治療効果異質性の間の理論的橋渡しを提供する。この接続は 3 つのステップで進む：

1. **W_1 と CDF 面積:** 一次元では、 $W_1(F_1, F_2) = \int |F_1(x) - F_2(x)| dx$ (式 3)、すなわち 2 つの CDF 間の総面積である。
2. **Kantorovich–Rubinstein 双対性:** $W_1(F_1, F_2) = \sup_{\|f\|_{\text{Lip}} \leq 1} |\int f dF_1 - \int f dF_2|$ 、すなわち W_1 はすべての 1-Lipschitz 関数にわたる期待値差の最大値に等しい (Villani 2009)。
3. **CATE への適用:** Lipschitz 定数 L を持つ任意の CATE 関数は τ/L が 1-Lipschitz であることを満たすため、双対性から直ちに $|\bar{\tau}_1 - \bar{\tau}_2| \leq L \cdot W_1(F_1, F_2)$ 、すなわち式 (2) が得られる。

この双対性は W_1 に固有のものである。 W_2 距離はガウス分布族に対する閉形式の表現を許すが、Lipschitz 関数を介したこの双対的特徴づけを持たず、したがって臨床校正フレームワークの中心となる異質性バウンドを提供できない。同様に、Kullback–Leibler (KL) ダイバージェン

スのような情報理論的ダイバージェンスには構造的限界がある：KL ダイバージェンスは非対称 ($D_{\text{KL}}(P\|Q) \neq D_{\text{KL}}(Q\|P)$) であり、地域プーリング決定の対称的性質と矛盾する；サポートが重複しない場合に無限大に発散し、これは経験分布でよく生じる；そして最も重要なことに、Lipschitz バウンド特性を欠いている——KL ダイバージェンスには Lipschitz 連続 CATE 関数に対する治療効果異質性への直接的な類似の結果がない (Gibbs & Su 2002)。Wasserstein 距離は三角不等式を満たし弱収束を距離化する真の距離であり (Villani 2009)、臨床較正フレームワークにとって自然な選択となる。

正規化累積分布間面積 (nABCD) は、Wasserstein-1 距離をプールされた四分位範囲の 2 倍で正規化したものとして定義される：

$$\text{nABCD}(F_1, F_2) = \frac{W_1(F_1, F_2)}{2 \cdot \text{IQR}_{\text{pooled}}} \quad (4)$$

ここでプール IQR は結合サンプルから計算される。IQR に基づく正規化は、**スケールフリーな解釈**を可能にし、外れ値に頑健であり、分布差を散布度の単位で表現する。

IQR は、標準偏差や Rousseeuw and Croux (1993) の Q_n 統計量のような代替的なスケール推定量に代えて選択した。IQR は EM 分布の中心 50% の散布度として直接解釈可能であり、非正規分布変数に対して中央値と IQR を日常的に報告する臨床研究者にとって馴染みのある量である。 Q_n はより高い崩壊点 (50% vs. 25%) とより高いガウス効率を提供するが、高い崩壊点ここでは不要である：EM 分布は集団レベルの量であり、汚染された測定データではないため、 Q_n の頑健性の優位性はこの設定では実現しない。

Proposition 1 (非負性)：有限の一次モーメントを持つ分布に対して、 $\text{IQR}_{\text{pooled}} > 0$ （すなわちプール分布が非退化）である限り、 $\text{nABCD} \geq 0$ であり、 $F_1 = F_2$ の場合にのみ等号が成立する。

Proposition 2 (異質性との接続)：CATE 関数が Lipschitz 定数 L を持つとき、

$$|\bar{\tau}_1 - \bar{\tau}_2| \leq 2L \cdot \text{IQR}_{\text{pooled}} \cdot \text{nABCD}(F_1, F_2) \quad (5)$$

証明: 式 (4) を式 (2) に代入すると、 $|\bar{\tau}_1 - \bar{\tau}_2| \leq L \cdot W_1(F_1, F_2) = L \cdot 2 \cdot \text{IQR}_{\text{pooled}} \cdot \text{nABCD}(F_1, F_2) = 2L \cdot \text{IQR}_{\text{pooled}} \cdot \text{nABCD}(F_1, F_2)$ が得られる。

2.2 推定

地域 1 からのサンプル $\{X_{1,i}\}_{i=1}^{n_1}$ および地域 2 からのサンプル $\{X_{2,j}\}_{j=1}^{n_2}$ が与えられたとき、nABCD は経験分布関数を用いて推定される：

$$\widehat{\text{nABCD}} = \frac{\sum_{k=1}^{n_1+n_2-1} |\hat{F}_1(x_{(k)}) - \hat{F}_2(x_{(k)})| \cdot (x_{(k+1)} - x_{(k)})}{2 \cdot \widehat{\text{IQR}}_{\text{pooled}}} \quad (6)$$

ここで $x_{(1)} < \dots < x_{(n_1+n_2)}$ は結合順序統計量である。

計算量: $O((n_1 + n_2) \log(n_1 + n_2))$ 、ソーティングが支配的。

推論にはノンパラメトリックパーセンタイルブートストラップを用い (del Barrio et al. 1999; Sommerfeld & Munk 2018)、 $B = 2,000$ 反復を使用する。次元では、 W_1 は CDF 間の L_1 距離に等しく、del Barrio et al. (1999) がブラウン橋の汎関数への $\sqrt{n}$ -収束を確立した；二標本への拡張は $\sqrt{n_1 n_2 / (n_1 + n_2)}$ のレートで標準的議論により従う。 $F_1 \neq F_2$ のとき、 L_1 汎関数の Hadamard 微分は線形であり—— $F_1(x) - F_2(x)$ の符号はほとんど至る所で一定である——したがって通常のノンパラメトリックブートストラップは一致性を持つ (Sommerfeld & Munk 2018)。 $F_1 = F_2$ の近傍では微分が非線形（凸集合上の上限）となり、素朴なブートストラップは穏やかなアンダーカバレッジを示しうるが、これは帰無近傍シナリオで観察された有限サンプルの挙動と整合的である（第 3 節参照）。

2.3 解釈と臨床較正

nABCD の中心的特徴は、Proposition 2 を通じた治療効果異質性との接続である。この接続は、固定閾値のみに依存するのではなく、臨床的に根拠のある解釈フレームワークの基盤を提供する。

2.3.1 異質性バウンドによる臨床較正

式 (5) より、EM 分布差に起因する地域平均治療効果の最大潜在差は：

$$\Delta_{\max} = 2L \cdot \text{IQR}_{\text{pooled}} \cdot \text{nABCD}(F_1, F_2) \quad (7)$$

ここで L は CATE 関数 $\tau(x)$ の EM に関する Lipschitz 定数であり、その EM に対する治療効果の臨床的感度を反映する。感度パラメータとしての L のこの使用法は、Armstrong and Kolesár (2021) が提案したフレームワークに従い、妥当な Lipschitz 定数の範囲にわたる信頼区間の報告を推奨したものである。所与の EM に対して、 L は事前知識、パイロットデータ、または公表されたサブグループ解析から推定できる。

臨床較正の手順：

1. 候補 EM を特定し、各 EM について地域ペアごとにブートストラップ CI つきの nABCD を計算する。
2. 各 EM について、事前知識から L を推定またはバウンドする（例：サブグループ解析で治療効果が EM の単位変化あたり $\Delta\tau$ 変動する場合、 $L \approx \Delta\tau/\Delta x$ ）。
3. 式 (7) を用いて $\Delta_{\max}$ を計算する。これは分布差に起因する最悪ケースの治療効果差を表す。
4. nABCD 信頼区間から $\Delta_{\max}$ のブートストラップ CI を導出する： $[\Delta_{\max,L}, \Delta_{\max,U}] = 2L \cdot \text{IQR}_{\text{pooled}} \cdot [\text{nABCD}_L, \text{nABCD}_U]$ 。これは推論的不確実性を臨床スケール上で直接表現する。

5. $\Delta_{\max}$ とその CI を臨床的文脈——例えば全体治療効果、非劣性マージン、最小臨床的重要差——とともに報告する。この情報により、試験設計者と規制科学者は、二値的な受容/棄却決定ではなく、エビデンスの総体を考慮してプーリングに関する臨床的判断を行うことができる。

この推定中心のアプローチは、プーリング決定を二値的仮説検定の枠組みに強制することを意図的に避けている。その理由は3つある。第一に、ICH E17 ガイドラインは「十分に類似」を本質的に文脈依存的と記述しており、この判断を棄却閾値に還元することは単純化のリスクがある。第二に、 L の不確実性は $\Delta_{\max}$ 自体が感度分析の対象であることを意味し（第4節）、二値検定はこの層状の不確実性を自然に収容できない。第三に、二分的な統計的決定を超えることへの最近の呼びかけ（Wasserstein 2016）と整合的に、CI つきの $\Delta_{\max}$ を提示することは、 p 値や棄却/非棄却の結果よりも規制審議に豊富な情報を提供する。

規制当局が正式な意思決定ルールを必要とする場合、推定フレームワークは適応可能である： $\Delta_{\max}$ の 95% CI の上限が事前に指定された臨床マージン Δ_{clin} を下回る場合にプーリングを許容可能と宣言する。ただし、これは nABCD フレームワークの補助的な使用として推奨する。

臨床較正の手順は、第4節において実際の臨床試験データを用いて実証する。そこでは、CATE 感度のエビデンスが対照的な2つの候補効果修飾因子が、完全な較正ワークフローと計画段階の評価ワークフローの双方を示す。

2.3.2 参照ベンチマーク

L の事前知識が利用できない場合、Table 3 のベンチマークが初期評価のための便宜的参照を提供する。これらのラベルは**分布の大きさのみ**を記述するものであり、臨床的有意性と混同すべきではない：第2.3節および第4節が示すように、弱い効果修飾因子に対する「大きな」nABCD は、強い効果修飾因子に対する「中程度の」nABCD よりも臨床的帰結が小さいことがありうる。なぜなら、CATE 感度 L が分布距離をいかに治療効果異質性に変換するかを決定するためである。

Table3: L が未知の場合の nABCD 値の参照ベンチマーク。これらのベンチマークは初期参照点としてのみ機能する；臨床的解釈は常に較正フレームワークを通じて進めるべきである。

nABCD 範囲	解釈	推奨アクション
< 0.05	無視できる差 (Negligible)	プーリングは広く支持可能
0.05–0.15	小さな差 (Small)	プーリングは一般的に許容可能
0.15–0.30	中程度の差 (Moderate)	臨床較正を実施
> 0.30	大きな差 (Large)	臨床較正が必須

3 シミュレーション研究 (Simulation Study)

nABCD 推定量の推定特性——バイアス、変動性、ブートストラップ信頼区間のカバレッジ確率——を評価するためにシミュレーション研究を実施した。これらの特性は臨床較正フレームワークにとっ

て不可欠であり、nABCD の信頼性の高い推定が $\Delta_{\max}$ 推定値の質を直接決定する。MRCT 応用に
関連するシナリオの範囲にわたって性能を評価した。

3.1 シミュレーション設計

3.1.1 シナリオ

方法論的検証のために 8 つの系統的シナリオを設計し、位置、スケール、形状、およびそれらの組み
合わせにわたる制御された分布差を検討した。Table 4 にこれらのシナリオとその真の nABCD 値を
要約する。

Table4: 臨床的動機付けによるシミュレーションシナリオ。S6 のガンマ分布は形状パラメータ 25、
レートパラメータ 0.5 であり、平均 50、標準偏差 10 を与える。S7 の対数正規は平均 50、 $CV \approx 53\%$
に合わせてパラメータ化。S8 は位置とスケールの差を組み合わせ、最も現実的な MRCT パターンを
表す。

ID	記述	分布 1	分布 2	真の nABCD
S1	帰無 (同一)	$N(50, 10^2)$	$N(50, 10^2)$	0.000
S2	位置 0.2σ	$N(50, 10^2)$	$N(52, 10^2)$	0.074
S3	位置 0.5σ	$N(50, 10^2)$	$N(55, 10^2)$	0.186
S4	位置 1.0σ	$N(50, 10^2)$	$N(60, 10^2)$	0.372
S5	スケール $1.5\times$	$N(50, 10^2)$	$N(50, 15^2)$	0.148
S6	形状 (ガンマ)	$N(50, 10^2)$	$\text{Gamma}(25, 0.5)$	0.067
S7	歪み (対数正規)	$N(50, 10^2)$	$\text{LogN}(\mu, \sigma)$	0.302
S8	位置+スケール	$N(50, 10^2)$	$N(55, 15^2)$	0.175

3.1.2 シミュレーションパラメータ

各シナリオについて、各地域 $n = 50, 100, 200$ のサンプルサイズで生成し、MRCT 地域サブグルー
プに典型的なサンプルサイズを反映した。シナリオ-サンプルサイズの各組み合わせについて 10,000
反復を実施し、操作特性の安定した推定を確保した (報告される全比率のモンテカルロ標準誤差は
0.005 未満)。ブートストラップ信頼区間は $B = 2,000$ リサンプルを用いて計算した。全シミュレー
ションは R version 4.3.3 で実施した。

3.1.3 評価指標

推定中心のフレームワークと整合的に、以下を評価した：

1. バイアス: $\text{Mean}(\widehat{\text{nABCD}}) - \text{nABCD}$
2. 二乗平均平方根誤差 (RMSE) : $\sqrt{\text{Mean}[(\widehat{\text{nABCD}} - \text{nABCD})^2]}$
3. カバレッジ確率: 95% ブートストラップ CI が真値を含む割合
4. CI 幅: ブートストラップ CI の平均幅 (推定精度を反映)

3.2 結果

3.2.1 点推定とカバレッジ

Table 5 に nABCD 推定量のバイアスをシナリオおよびサンプルサイズ別に示す。推定量は帰無仮説下 (S1) で正のバイアスを示し、バイアスは $n = 50$ の 0.093 から $n = 200$ の 0.047 に減少した。この正のバイアスは Wasserstein 距離の非負性に起因する：真の nABCD がゼロであっても、サンプリング変動が正の推定値を生成する。

Table5: シナリオおよびサンプルサイズ別の nABCD 推定量のバイアス。バイアスは $\text{Mean}(\widehat{\text{nABCD}}) - \text{nABCD}$ として定義。 $B = 2,000$ ブートストラップリサンプルによる 10,000 反復に基づく結果。

シナリオ	真の nABCD	バイアス $n=50$	バイアス $n=100$	バイアス $n=200$
S1 (帰無)	0.000	+0.093	+0.066	+0.047
S2 (0.2σ)	0.074	+0.038	+0.018	+0.007
S3 (0.5σ)	0.186	+0.004	- 0.002	- 0.005
S4 (1.0σ)	0.372	- 0.039	- 0.041	- 0.042
S5 (スケール)	0.148	+0.002	- 0.012	- 0.019
S6 (形状)	0.067	+0.028	+0.003	- 0.015
S7 (歪み)	0.302	+0.019	+0.009	+0.005
S8 (位置 + スケール)	0.175	+0.024	+0.011	+0.006

ほとんどの非帰無シナリオで $n \geq 100$ においてバイアスの絶対値は 0.02 未満であり、実用的なサンプルサイズでの十分な点推定性能を示す。S4 (1.0σ の位置シフト) では、nABCD の理論的上限範囲近傍での有界性を反映して、約 - 0.04 の負のバイアスがすべてのサンプルサイズで持続した (図 2 参照)。新しいシナリオ S7 (対数正規) と S8 (位置 + スケール) は、中間範囲の真の nABCD 値に期待されるパターンに従い、サンプルサイズの増加に伴い縮小する小さな正のバイアスを示した。

Table 6 に 95% ブートストラップ信頼区間のカバレッジ確率を示す。 $n \geq 100$ では、ほとんどのシナリオでカバレッジは 0.87–0.98 の範囲内であり、S2 は $n = 100$ で中程度のアンダーカバレッジ (0.896) を示した。S4 は n の増加に伴い漸進的なアンダーカバレッジを示し ($n = 100$ で 0.874、 $n = 200$ で 0.740)、大きな分布差における持続的な負のバイアスに起因する。 $n = 50$ では、アンダーカバレッジがより顕著であり、特に S6 (0.576) と S2 (0.669) で、このサンプルサイズが信頼性のある推論には不十分であることを示す。

カバレッジは形状シナリオ (S6) でサンプルサイズに対して非単調なパターンを示した： $n = 50$ で 0.576、 $n = 100$ で 0.949、 $n = 200$ で 0.997。 $n = 50$ の低いカバレッジは CI 幅に対する大きな正のバイアスを反映し、 $n = 200$ のオーバーカバレッジは縮小するバイアス (- 0.015) と、この小さな真値に対して相対的に広いま残る CI の組み合わせを反映している。新しいシナリオ S7 (歪み) と

S8（位置 + スケール）は優れたカバレッジを示した：S7 はすべてのサンプルサイズでほぼ名目どおりのカバレッジ（0.951–0.954）を達成し、S8 はサンプルサイズの増加に伴い改善するわずかなアンダーカバレッジ（ $n = 50$ で 0.916 から $n = 200$ で 0.939）を示した。

BCa（バイアス修正加速）信頼区間も評価した。BCa 区間はすべてのシナリオでパーセンタイル区間より一貫して低いカバレッジを示し、最大の乖離はスケールおよび形状シナリオにあった（例：S5 の $n = 100$: パーセンタイル 0.979 vs. BCa 0.841; S6 の $n = 200$: パーセンタイル 0.997 vs. BCa 0.493）。BCa 修正は nABCD に対して過修正となるが、これは統計量がゼロ以下にバウンドされているため、加速パラメータが分位点調整を歪めるためである。これらの知見に基づき、**パーセンタイルブートストラップを主要推論方法として採用した**。

報告されたすべてのカバレッジ確率のモンテカルロ標準誤差は 10,000 反復で 0.005 未満であり、シナリオおよびサンプルサイズ間の観察された差異がシミュレーションノイズではなく真の操作特性の差異を反映していることを保証する。

Table6: 95% パーセンタイルブートストラップ信頼区間のカバレッジ確率。S1（帰無）のカバレッジは、真値 0 がパラメータ空間の境界上にあるため報告しない。S4（大効果）では、精度の向上が持続的な負のバイアスを明らかにすることにより、大サンプルサイズでカバレッジが低下した。

シナリオ	カバレッジ		
	カバレッジ $n=50$	$n=100$	$n=200$
S2 (0.2σ)	0.669	0.896	0.943
S3 (0.5σ)	0.950	0.949	0.951
S4 (1.0σ)	0.928	0.874	0.740
S5（スケール）	0.962	0.979	0.933
S6（形状）	0.576	0.949	0.997
S7（歪み）	0.953	0.954	0.951
S8（位置 + スケール）	0.916	0.932	0.939

3.2.2 推定精度

推定品質のシナリオおよびサンプルサイズにわたる要約を、カバレッジ確率と平均 CI 幅の両方で示す（図 3 参照）。

Table 7 に RMSE と平均 CI 幅をシナリオ別に示す。RMSE は n の増加に伴い一貫して減少し、 $n = 200$ ですべてのシナリオで 0.06 未満の値に達した。平均 CI 幅は比例して狭まり、 $n = 100$ の CI は典型的に 0.11–0.19 nABCD 単位にまたがる。臨床校正フレームワークでは、この CI 幅は $\Delta_{\max}$ に伝播する：例えば、 $L = 0.3$ かつ $IQR = 1.5$ の場合、nABCD の CI 幅 0.13 は $2 \times 0.3 \times 1.5 \times 0.13 = 0.12\%$ HbA1c の CI 幅に対応する——意味のある臨床校正に十分な精度水準である。

Table7: シナリオおよびサンプルサイズ別の RMSE と平均 CI 幅。CI 幅は 10,000 反復にわたる（上限－下限）の平均として定義。

シナリオ	RMSE $n=50$	RMSE $n=100$	RMSE $n=200$	CI 幅 $n=50$	CI 幅 $n=100$	CI 幅 $n=200$
S1（帰無）	0.100	0.070	0.050	0.16	0.11	0.08
S2（ 0.2σ ）	0.060	0.043	0.032	0.18	0.13	0.11
S3（ 0.5σ ）	0.066	0.049	0.035	0.23	0.18	0.13
S4（ 1.0σ ）	0.073	0.060	0.052	0.24	0.17	0.12
S5（スケール）	0.045	0.035	0.031	0.19	0.13	0.09
S6（形状）	0.045	0.024	0.023	0.16	0.11	0.08
S7（歪み）	0.070	0.048	0.034	0.27	0.19	0.13
S8（位置＋スケール）	0.062	0.043	0.031	0.22	0.16	0.12

帰無仮説下（S1）では、正のバイアスにより CI がゼロから上方にシフトする。 $n = 50$ で平均推定値は 0.093、平均 CI 幅は 0.16 であった； $n = 200$ では平均推定値は 0.047 に減少し、平均 CI 幅は 0.08 であった。このバイアスは臨床校正に関連する：真の分布差がゼロのとき、推定量は小さな正の $\Delta_{\max}$ を示唆する。実務者はこの保守的傾向に留意すべきであり、特に小さなサンプルサイズでは注意が必要である。

3.2.3 標準化平均差との比較

Table 8 は nABCD と SMD の異なるタイプの分布差に対する感度を比較する。両指標とも位置シフトに応答するが、SMD は分散と形状の差に鈍感である——まさに非線形 CATE 関数を通じて治療効果異質性を駆動しうるタイプの分布差である。

Table8: nABCD 対 SMD の感度比較（ $n = 100$ ）。SMD は平均の差のみに依存するため、分散・形状・歪度の差に対して鈍感である。

シナリオ	nABCD (平均 $\pm$ SD)	SMD (平均 $\pm$ SD)	含意
S3（位置）	0.184 ± 0.049	0.50 ± 0.14	両方検出
S5（スケールのみ）	0.136 ± 0.033	0.00 ± 0.14	nABCD のみ検出
S6（形状のみ）	0.070 ± 0.024	0.00 ± 0.14	nABCD のみ検出
S7（歪みのみ）	0.311 ± 0.047	0.00 ± 0.14	nABCD のみ検出

（図 4 参照）

3.2.4 シミュレーション結果の要約

要約すると、8つのシナリオにわたるシミュレーション研究は、nABCD 推定量が MRCT 地域サブグループに典型的なサンプルサイズにおいて、以下の特性で信頼性の高い推定を提供することを示した：

1. **バイアス**: ほとんどの非帰無シナリオで $n \geq 100$ において 0.02 未満。S4 は大きな真値での境界効果により -0.04 の持続的バイアスを示す
2. **カバレッジ**: ほとんどのシナリオで $n \geq 100$ において 0.87–0.98。新シナリオ S7（歪み）と S8（位置 + スケール）は 0.93–0.95 のカバレッジを達成
3. **精度**: $n \geq 100$ で RMSE が 0.06 未満、CI 幅が 0.19 未満
4. **感度**: SMD が位置のみに限定されるのに対し、位置・スケール・形状の差を捕捉

シナリオ S3 (0.5σ の位置シフト、真の nABCD = 0.186) は、臨床的に関連する効果量での操作特性を例示する：バイアスは無視できる ($n = 100$ で -0.002)、カバレッジは名目どおり (0.949)、CI 幅 (0.18) は $L = 0.3$ 、 $IQR = 1.5$ で校正すると $2 \times 0.3 \times 1.5 \times 0.18 = 0.16\%$ HbA1c の $\Delta_{\max}$ CI 幅に変換され——情報に基づく規制審議に十分な精度水準である。

これらの推定特性は、nABCD が臨床校正フレームワークと組み合わせられたとき、規制審議に十分な品質の $\Delta_{\max}$ 推定値を提供することを保証する。 $n \geq 100$ を各地域について推奨する。

4 適用事例：多地域臨床試験計画における統合的シナリオ

nABCD フレームワークの実務的価値を示すため、同じ臨床領域（脳卒中）から得られた2つの相補的な国際共同試験データを用いた統合的なシナリオを提示する。スポンサーが急性虚血性脳卒中に対する新規血栓溶解薬の多地域臨床試験を計画する際、「どの地域の EM 分布がプーリング戦略の変更を必要とするのか？」という問いに直面する。この質問への答えは、CATE 感度に関する既知の情報に依存する：

- **シナリオ A (EM 未同定)**：治療 $\times$ EM 交互作用の事前エビデンスが不在または非有意の場合、分布異質性のみが意思決定を導く。これは MRCT 計画時の最も一般的な状況である。
- **シナリオ B (EM 同定)**：事前エビデンスが EM 状態を確認し、CATE 感度が推定可能な場合、臨床校正が可能となり、分布差を臨床的影響に変換できる。

IST-1 (シナリオ A)：第1回国際脳卒中試験 (1991–1996 年) は 19,435 例の患者を 5 大陸 31 ヶ国にわたってアスピリン、ヘパリン、または対照群に無作為化した。本試験は EM 検出を目的として設計されず；Chen et al. (2000) は 28 サブグループにわたる有意な治療 $\times$ EM 交互作用を見つけなかった。IST-1 の世界的範囲（インド、シンガポール、香港などアジア地域を含む）により、最小限の事前仮定の下での地理的分布異質性の評価が可能である。

IST-3 (シナリオ B)：第3回国際脳卒中試験 (2000–2012 年) は急性虚血性脳卒中患者 3,035 例をアルテプラザーまたは対照群に 12 ヶ国にわたって無作為化した。Emberson et al. (2014) の IPD

メタ解析は血栓溶解薬試験における確認された EM (NIHSS、交互作用 $p = 0.06$; 年齢 $p = 0.53$; 治療遅延 $p = 0.016$) を同定した。IST-3 は、CATE 感度の推定と、nABCD の臨床的に意味のある $\Delta_{\max}$ 値への較正に必要な事前エビデンスを提供する。私たちは $n \geq 50$ の IST-3 の 8 ヶ国を解析対象に含めた (Table 9)。

両試験は本現在、方法論的イラストレーションとして遡及的に解析される。いずれも MRCT として前向きに設計されなかったが、実際の Phase 3 計画時にスポンサーが直面する意思決定環境を体現している。

4.1 統合シナリオとデータ: 二層構造フレームワーク

Third International Stroke Trial (IST-3) は、急性虚血性脳卒中患者 3,035 例を発症 6 時間以内にアルテプラゼ ($n = 1,515$) と対照群 ($n = 1,520$) に 12 ヶ国にわたって無作為化した国際共同試験である (IST-3 collaborative group 2012)。IST-3 は MRCT として設計されたものではない; 本論文では事後的な方法論的例示として使用し、その国レベルのデータをスポンサーが Phase 3 計画時に遭遇する地域 EM 分布の代理として扱う。 $n \geq 50$ の 8 ヶ国を解析対象に含めた (Table 9)。

候補 EM は先行文献——特に Emberson et al. (2014) のメタ解析——から同定され、薬剤 A の Phase 2 データからではない。治療遅延 (Emberson $p = 0.016$) は 3 番目の候補 EM として含める; その高度に歪んだ分布 (全体の歪度 = 1.21、超過尖度 = 20.0) は、nABCD と SMD の比較における自然なテストケースを提供する。

Table9: IST-3 国別ベースライン特性。UK が全体の 48% を占めた。Belgium ($n = 73$) と Portugal ($n = 82$) は推奨最小サンプルサイズ $n \geq 100$ を下回る。

国	n	年齢, 平均 (SD)	遅延, 平均 (SD)	NIHSS, 平均 (SD)
UK	1,447	78.0 (12.2)	4.1 (1.2)	13.1 (6.9)
Poland	347	73.7 (13.1)	4.6 (1.2)	9.6 (6.4)
Italy	326	75.9 (12.2)	4.2 (1.1)	11.1 (6.6)
Sweden	297	81.0 (10.8)	3.8 (1.3)	10.0 (6.5)
Norway	204	76.1 (10.3)	4.3 (1.8)	11.9 (6.9)
Australia	179	74.7 (13.1)	4.6 (1.1)	14.4 (7.5)
Portugal	82	79.0 (11.5)	4.3 (1.2)	14.8 (6.0)
Belgium	73	76.1 (12.4)	4.0 (1.1)	10.9 (6.1)

4.2 分布比較: nABCD 対 SMD

NIHSS、年齢、および治療遅延について全 28 ヶ国ペアの nABCD と SMD (Austin 2011) を計算した。Table 10 に nABCD の結果を要約する。

Table10: IST-3 における 28 ペアワイズ国比較の nABCD 要約。歪度はプールサンプルから計算。治療遅延は最大の正の歪度と超過尖度 (= 20.0) を示す。

EM 候補	歪度	最小	中央値	平均	最大	最大ペア
年齢 (歳)	-1.26	0.039	0.103	0.123	0.285	Sweden– Belgium
NIHSS (スコア)	0.49	0.027	0.101	0.113	0.240	Poland– Portugal
治療遅延 (時間)	1.21	0.026	0.098	0.107	0.195	Sweden– Australia

治療遅延は nABCD と SMD の最も有益な比較を提供する。その高度に歪んだ重い裾の分布が、位置ベースの指標が誤解を招く状況を生み出すためである。28 ペアにわたる $|SMD|$ と nABCD の Pearson 相関は、治療遅延で 0.91 であり、年齢の 0.95 および NIHSS の 0.98 と比較して低い——治療遅延のスケールおよび形状の国間異質性がより大きいことを反映している。

Norway–Portugal ペアは特に例証的である：両国はほぼ同一の平均治療遅延を持つ (4.34 vs. 4.33 時間; $SMD = 0.007$) にもかかわらず、nABCD は 0.069 であり——SMD には見えない非自明な分布差を示す。この乖離は、Norway の治療遅延分布が極端な右裾に支配されている (歪度 = 6.76、範囲は最大 24.3 時間、 $SD = 1.80$) のに対し、Portugal の分布はよりコンパクトである (歪度 = -0.23、 $SD = 1.21$) ことに起因する。平均の差のみに依存する SMD は、これらの分布を本質的に同一と扱う。Poland–Norway ペアもこのパターンをさらに例証する：中程度の SMD 0.151 にもかかわらず、nABCD は 0.115 (比率 0.76) に達し、両国間の大きなスケール差 ($SD = 1.16$ vs. 1.80) を反映している。これらのケースは、シミュレーションのシナリオ S5 (スケール) および S7 (歪み) の知見と並行する——nABCD が SMD では完全に検出できなかった分布差を捕捉した。

年齢と NIHSS では、nABCD と $|SMD|$ はより強く相関していた。国間の差が主に位置 (平均) シフトに起因し、分散が比較的均質であったためである。これは予想される挙動である：分布が近似的に正規で等分散の場合、nABCD と SMD は同様の情報を伝える。nABCD の実務的優位性は、まさに EM の分布が正規性から逸脱する場合——バイオマーカー、イベントまでの時間変数、フロアまたはシーリング効果を持つ臨床スコアでよく見られるように——に発揮される。

4.3 臨床較正: NIHSS

NIHSS は EM としての最も強い事前エビデンスを有する：Embersson et al. (2014) は治療 × NIHSS 交互作用 $p = 0.06$ を報告し、IST-3 データでは $p = 0.001$ であり、CATE 感度 L が合理的な精度で推定可能であることを示す。薬剤 A に対する真の L は未知である。同じクラスの参照として IST-3 から得られたアルテプラザーゼベースの推定値を借用し、感度分析を実施する。IST-3 のロジスティック回帰 (治療 × NIHSS 交互作用項、アウトカム: 6 ヶ月時 OHS 0–2) に続く marginal standardization により、 $L_{\text{mean}} = 0.00950/\text{pt}$ および $L_{\text{max}} = 0.01398/\text{pt}$ を推定した (Table 11)。

Table11: nABCD の臨床較正: CATE 感度推定と $\Delta_{\max}$ 。 $\Delta_{\max}$ はリスク差 (% ポイント) で表現。全体治療効果の RD $\approx +1.5\%$ pt。

EM 候補	交互作用		nABCD 最大	$\Delta_{\max}$ ($L_{\max}$)	$\Delta_{\max}$ (L_{mean})
	p 値	$L_{\max}$			
NIHSS	0.001	0.01398/pt	0.00950/pt	0.240	7.37%pt
年齢	0.614	0.00090/yr	0.00065/yr	0.285	0.65%pt

最大 nABCD ペア (Poland–Portugal, nABCD = 0.240) について、アルテプラーゼベースの L_{mean} による $\Delta_{\max}$ は 5.02%pt であり、全体治療効果 (RD $\approx 1.5\%$ pt) を大幅に超える。クラス転移可能性の仮定に対する頑健性を評価するため、 L をアルテプラーゼ推定値の $0.5\times$ から $2\times$ の範囲で変化させた: $0.5L_{\text{mean}}$ で $\Delta_{\max} = 2.51\%$ pt; $2L_{\text{mean}}$ で $\Delta_{\max} = 10.04\%$ pt。この範囲全体にわたり、NIHSS 分布差は臨床的に意味のある潜在的治療効果異質性に変換され、薬剤 A の正確な L 値にかかわらず、プーリング戦略において注意が必要であることを示す。

4.4 計画段階の評価: 年齢

年齢は EM としての弱いエビデンスを有する: Emberson et al. (2014) は $p = 0.53$ を報告し、IST-3 データも非有意性を確認した ($p = 0.614$)。推定された CATE 感度は小さく ($L_{\text{mean}} = 0.00065/\text{yr}$)、不確実性が大きい。

弱い EM エビデンスを考慮し、主要評価には nABCD と参照ベンチマーク (Table 3) を使用する。年齢の最大ペアワイズ nABCD は 0.285 (Sweden–Belgium) であり、「中程度の差」の範囲に位置する。いかなる候補 EM の中でも最大の分布差を示すにもかかわらず、臨床較正は小さな $\Delta_{\max}$ を与える: L_{mean} を用いて 0.47%pt、 $L_{\max}$ を用いて 0.65%pt (Table 11)。 $2L_{\text{mean}}$ としても $\Delta_{\max}$ は 0.94%pt に留まり、全体治療効果を下回る。計画地域にわたる年齢分布の差は、臨床的に意味のある治療効果異質性を生成する可能性が低い。

4.5 実務的含意

NIHSS と年齢の対比が、nABCD フレームワークの中心的原理を体現している: 同じ nABCD の大きさが CATE 感度に応じて大きく異なる臨床的帰結を持ちうる。年齢は最大の分布差 (nABCD = 0.285) を示しながら最小の臨床的影響 ($\Delta_{\max} = 0.47\%$ pt) に変換され、NIHSS は中程度の分布差 (nABCD = 0.240) でありながら桁違いに大きな臨床的影響 ($\Delta_{\max} = 5.02\%$ pt) を持つ。このことは、nABCD の大きさのみではプーリング決定に不十分であり、臨床較正が必要な文脈を提供することを強調する。

治療遅延は nABCD の分布的優位性を最も明確に例証する: 確認された EM (Emberson $p = 0.016$) であるにもかかわらず、その高度に歪んだ分布は SMD を地域間類似性の評価において信頼性の低いものにする。第 4.2 節で示したように、Norway–Portugal ペアは SMD ≈ 0 であるにもかかわらず

nABCD = 0.069 であり、この乖離はスケールおよび形状の差によって完全に駆動されている。この知見は実務的リスクを例証する：SMD のみに依拠するスポンサーは、これらの地域間で治療遅延分布が同一であると結論づけ、治療効果異質性の源泉を潜在的に見落とすことになる。IST-3 データは非有意な治療 × 遅延交互作用 ($p = 0.567$) を示し、 L 推定値自体の信頼性が慎重な検討を要する設定を例証している；それにもかかわらず、nABCD が検出した分布的非対称性はプーリング根拠において認識に値する。

限界と注意点:

1. **事後的解析:** IST-3 は MRCT として設計されたものではない；本適用事例は方法論の実現可能性を示すものであり、前向き使用ではない。
2. **小サンプル国:** Belgium ($n = 73$) と Portugal ($n = 82$) は推奨最小サンプルサイズ ($n \geq 100$) を下回り；これらの国を含むペアのブートストラップ CI は相対的に広い。
3. **L の転移可能性:** CATE 感度はアルテプラザーゼデータから推定されたものであり、薬剤 A からではない；クラス転移可能性の仮定は正当化と上記で示した感度分析を必要とする。
4. **時間的一般化可能性:** IST-3 は 2000–2011 年に患者を登録した；脳卒中集団の人口動態の変化が現在の試験計画への適用可能性を制限しうる。
5. **地理的カバレッジ:** IST-3 の参加国は計画する Phase 3 地域と一致しない可能性がある；EM 分布は歴史的参照としてのみ機能する。

5 考察 (Discussion)

MRCT における EM 分布を比較するための正規化指標 nABCD を開発・検証した。貢献は以下の通り：(1) nABCD 指標そのもの——Wasserstein-1 距離と IQR 正規化およびパーセンタイルブートストラップ推論を組み合わせた、SMD が見逃す完全な分布差（スケール、形状、歪度を含む）を捕捉する指標；(2) Kantorovich–Rubinstein 双対性と異質性バウンドを通じて nABCD と治療効果異質性を接続する理論的フレームワーク；(3) CATE 感度 L が推定可能な場合に nABCD を文脈特異的な $\Delta_{\max}$ 評価に変換する条件付きツールとしての臨床較正；(4) nABCD が SMD では見えない分布的特徴を捕捉することの IST-3 データによる比較実証——特に高度に歪んだ治療遅延分布において、実質的なスケールおよび形状の差にもかかわらず SMD ≈ 0 であったケース；(5) フレームワークの柔軟性の二重実証——NIHSS の完全な較正 (L が推定可能) と年齢の計画段階の分布評価 (L が不確実) の双方を通じた。

nABCD 指標は現行アプローチの限界に対処する。SMD との比較では、nABCD は分散と形状を含む完全な分布差を捕捉する。シミュレーションは、SMD 推定値がゼロ近傍にとどまるスケール差 (S5)、形状差 (S6)、歪度差 (S7) を nABCD が捕捉することを実証した；IST-3 への適用は実データでこのパターンを確認し、治療遅延の歪んだ分布が Norway と Portugal 間で nABCD = 0.069 であるにもかかわらず SMD ≈ 0 を生じた。KS 統計量との比較では、nABCD は異質性バウンド (式 7) を通じた治療効果異質性への直接的接続を提供し、純粋に統計的な評価ではなく臨床較正を可能にする。目視検査との比較では、nABCD は客観的かつ再現可能である。本アプローチは、観察された治療効果が地域間で一致するかどうかを評価する治療効果一貫性評価方法 (Quan et al. 2010) と

は概念的に異なる；nABCD はその上流で機能し、そのような異質性を駆動しうる効果修飾因子分布の類似性を定量化する。

第 2.3 節で導入した臨床校正手順は、固定閾値アプローチからの脱却を表す。Cohen の d ベンチマーク（小=0.2, 中=0.5, 大=0.8）は文脈フリーな適用に対して広く批判されており、我々はこのパターンを意図的に避ける。代わりに、異質性バウンドが nABCD を臨床的に意味のある単位に変換する原理に基づくメカニズムを提供し、「十分に類似」が文脈依存的であるという ICH E17 の原則を尊重する。臨床校正の自然な帰結として、分布距離と臨床的影響のランキングは異なりうる——IST-3 では年齢が最大の nABCD ながら最小の $\Delta_{\max}$ であった——同じ分布差が CATE 感度に応じて異なる臨床的重みを持つためである。より広くは、IST-3 適用事例は、同じ nABCD フレームワークが CATE 感度エビデンスの利用可能性に応じて異なる目的に機能することを示した：NIHSS では L が推定可能であり、完全な校正が分布差を臨床的に解釈可能な $\Delta_{\max}$ 値に変換した；年齢では L が不確実であり、nABCD と参照ベンチマーク（Table 3）が分布類似性の主要評価を提供した。この接続は、分布距離と潜在的治療効果異質性を関連づける transportability 理論 (Pearl & Bareinboim 2011; Bareinboim & Pearl 2016) に基づく。

本研究の知見に基づき、実務者に以下の推奨を提供する：

1. 各候補 EM について、地域ペアごとにブートストラップ CI 付き nABCD を計算する（各地域 $n \geq 100$ ）。
2. 式 (7) を用いて nABCD を臨床アウトカムスケール上の $\Delta_{\max}$ とその CI に変換し、CATE 感度 L の事前知識または推定値を組み込む。 L をデータから推定する場合、IST-3 適用事例（第 4 節）のように、 $L_{\max}$ （保守的上限）と L_{mean} （現実的推定）の双方を報告する。
3. $\Delta_{\max}$ とその CI を、全体治療効果、非劣性マージン、その他の臨床的に関連するベンチマークとともに報告し、プーリングに関する情報に基づく審議を支援する。
4. 事前知識が不確実な場合、 L の妥当な値にわたる感度分析を実施する。
5. L が推定できない場合、Table 3 の参照ベンチマークを初期ガイダンスとして使用するが、臨床校正がより厳密な意思決定基盤を提供することを認識する。

実務では、複数の候補 EM が同時に評価される場合がある。nABCD フレームワークは各 EM を個別に評価し、すべての候補 EM について全地域ペアにわたる $\Delta_{\max}$ とその CI を報告することを推奨する。全体的なプーリング推奨に至るため、試験設計者は保守的アプローチ（すべての EM と地域ペアにわたる最大 $\Delta_{\max}$ に基づく）を採用するか、エビデンスの総体アプローチ（ $\Delta_{\max}$ 値のコレクション、その不確実性、各 L 推定値の信頼性が総合的判断に情報を提供する）を採用しうる。これらの戦略間の選択は規制上の文脈に依存する：正式なプーリング基準が必要なアプリケーションでは最大 $\Delta_{\max}$ が防御可能な最悪ケース評価を提供し；臨床的審議によってプーリング決定が情報提供される助言的設定では、校正結果の完全なセットがより豊富なエビデンス基盤を提供する。

CATE 感度 L の実務的な利用可能性は場面により異なる。同じ治療領域の先行試験やメタ解析から L が推定可能な場合、IST-3 適用事例の NIHSS で示したように完全な臨床校正が可能である。しかし MRCT 計画段階では、 L は不確実であることが多い——特に新規薬剤やサブグループ解析が不足する治療領域では。そのような場合、nABCD と参照ベンチマーク（Table 3）が分布類似性の主要

評価を提供し、妥当な L 範囲にわたる感度分析で補完される。重要なことに、nABCD の分布指標としての中核的価値——SMD では見えないスケール・形状・歪度の差を捕捉すること——は L が利用可能であるか否かにかかわらず成り立つ；臨床較正はこの分布評価を強化するものであり、代替するものではない。

限界として以下を認識すべきである：

1. **連続 EM のみ**：現在の定式化は連続型 EM にのみ適用可能であり、カテゴリカルまたは混合型 EM への拡張にはさらなる開発が必要である。
2. **単変量**：nABCD は各 EM を同時にではなく個別に評価する；多変量拡張が EM 間の潜在的な交絡に対処する。
3. **バイアス特性**：小サンプル ($n < 100$) での帰無仮説下の正のバイアスは nABCD 推定値を膨張させうるし、大きな真値 (S4, nABCD = 0.372) での持続する負のバイアスは漸進的なアンダーカバレッジ ($n = 200$ で 0.740) をもたらす。これらの境界効果は、Wasserstein 距離の関数としての nABCD の非負・有界の性質に固有である。真値がゼロに等しい場合、パラメータはパラメータ空間の境界上にあり、標準的なブートストラップ一致性の結果は適用されない可能性がある (Andrews 2000)；したがって帰無シナリオのカバレッジは報告せず、ゼロ近傍の nABCD 推定値は注意して解釈することを推奨する。非帰無シナリオでは、真値はパラメータ空間の内部にあり標準的なブートストラップ一致性が成り立ち、シミュレーションはほとんどのシナリオで $n \geq 100$ において 0.87–0.98 のカバレッジで確認している；特筆すべきは、新シナリオ S7 (歪み) と S8 (位置 + スケール) がすべてのサンプルサイズで 0.93–0.95 のカバレッジを達成したことである。カバレッジは非単調な挙動も示しうる：形状シナリオ (S6) ではカバレッジは $n = 50$ で 0.576、 $n = 100$ で 0.949、 $n = 200$ で 0.997 であり、バイアスの大きさと CI 幅のバランスがサンプルサイズとともにどのように変化するかを反映している。パーセンタイルブートストラップを使用しており、これは一次精度である；BCa のようなバイアス修正法はこの有界統計量に対して劣った性能を示し (第 3.2.1 節)、studentized bootstrap は Wasserstein 距離比率の分散推定を必要とし実質的な複雑性を加える。各地域 $n \geq 100$ を信頼性のある点推定と信頼区間に推奨し、真の nABCD が約 0.3 を超える場合にカバレッジが低下しうることに注意を喚起する。
4. **L の必要性**：臨床較正には CATE 感度 L の推定が必要であり、事前データから常に利用可能とは限らない。参照ベンチマークを代替手段として提供するが、文脈特異的な較正に代わるべきではない。
5. **複数の EM**：複数の効果修飾因子が関連する場合、現在のフレームワークは各 EM を個別に評価する。効果修飾因子間で nABCD 値を統合する集約戦略——臨床的重要性を反映した重み付け組み合わせや高次元最適輸送を用いた多変量拡張など——は今後の研究課題である。
6. **測定された EM のみ**：共変量に基づくアプローチ全般と同様に、nABCD は測定された効果修飾因子に関してのみ類似性を評価する。測定されていない、または未知の効果修飾因子が、指標が捕捉する範囲を超えて治療効果異質性に寄与しうる。
7. **L の転移可能性**：IST-3 適用事例で示した臨床較正はアルテプラゼからの CATE 感度推定値を使用した；同じ薬理クラスの他の薬剤への L の転移可能性は臨床的判断を必要とする仮定であり、感度分析が有益でありうる。

8. **IST-3 の時間的制約:** IST-3 のデータは 2000–2011 年に収集された；人口動態的および臨床実践の変化が、これらの国レベル EM 分布の現代の試験計画への適用可能性を制限しうる。

今後の研究は、多変量拡張、小サンプル用バイアス修正法、実際の MRCT データを用いた CATE 感度パラメータの経験的較正に取り組むべきである。歴史的試験データベースからの L の推定方法は臨床較正フレームワークを強化するであろう。nABCD フレームワークは縦断的 EM プロファイルにも拡張可能であり、時間経過にわたる分布類似性の動的評価を可能にする。

nABCD 指標をブートストラップ推論および本論文で述べた臨床較正フレームワークとともに実装する R パッケージが開発中である。

nABCD は、「十分に類似」を固定閾値に還元するのではなく、原理に基づく分布類似性評価のフレームワークを提供することにより、ICH E17 実装における方法論的ギャップを埋める。臨床較正手順は、分布差を潜在的治療効果異質性の文脈特異的な評価に変換し、エビデンスに基づき臨床的に根拠のあるプーリング決定を可能にする。オープンソース R コードが採用促進のために利用可能である。

付録

付録 A: 証明と数学の詳細

A.1 Proposition 1 の証明 (非負性)

非負性は Wasserstein-1 距離の非負性から直接従う： $W_1(F_1, F_2) = \int |F_1(x) - F_2(x)| dx \geq 0$ であり、すべての x について $F_1(x) = F_2(x)$ の場合にのみ等号が成立する。非退化分布に対して $\text{IQR}_{\text{pooled}} > 0$ であるから、比率 $\text{nABCD} = W_1/(2 \cdot \text{IQR}_{\text{pooled}}) \geq 0$ である。

A.2 漸近的性質

標準的な正則条件のもとで、経験的 Wasserstein-1 距離 $W_1(\hat{F}_1, \hat{F}_2)$ は $W_1(F_1, F_2)$ の一致推定量である (del Barrio et al. 1999)。経験的 IQR の一致性と合わせて、 $\widehat{\text{nABCD}}$ は $\text{nABCD}(F_1, F_2)$ の一致推定量である。

一次元では、経験的 W_1 距離は対数修正なしに $O(n^{-1/2})$ のレートで収束する (del Barrio et al. 1999)。 $F_1 \neq F_2$ の二標本推定で有限二次モーメントのもと、 $\sqrt{n}(W_1(\hat{F}_{1,n_1}, \hat{F}_{2,n_2}) - W_1(F_1, F_2))$ は平均ゼロのガウス分布に分布収束する ($n = n_1 + n_2$, $n_1/n \rightarrow \lambda \in (0, 1)$)。経験的 IQR も標準的な密度条件のもとで $O(n^{-1/2})$ のレートで収束するため、比率 $g(w, q) = w/(2q)$ に対するデルタ法により $\widehat{\text{nABCD}}$ の漸近正規性が得られる：

$$\sqrt{n}(\widehat{\text{nABCD}} - \text{nABCD}(F_1, F_2)) \xrightarrow{d} N(0, \sigma_{\text{nABCD}}^2)$$

ここで σ_{nABCD}^2 は W_1 と IQR 推定量の漸近分散と共分散に依存する。この結果は $\text{nABCD} > 0$ (すなわち $F_1 \neq F_2$) を要求する；境界 $F_1 = F_2$ では、パラメータがパラメータ空間の端にあり、標準的漸近論は適用されない (第 5 節参照)。

ブートストラップは緩い条件のもとで Wasserstein 距離に対する妥当な推論を提供する (Sommerfeld & Munk 2018)。パーセンタイルブートストラップ信頼区間は、非退化分布に対して漸近的に正しいカバレッジを達成する。

付録 B: nABCD 計算の R コード

```
compute_nABCD <- function(x1, x2) {
  pooled <- c(x1, x2)
  iqr_pooled <- IQR(pooled)
  if (iqr_pooled == 0) return(NA)
  all_vals <- sort(unique(pooled))
  F1 <- ecdf(x1); F2 <- ecdf(x2)
  w1 <- sum(diff(all_vals) *
    abs(F1(all_vals[-length(all_vals)]) -
      F2(all_vals[-length(all_vals)])))
  w1 / (2 * iqr_pooled)
}

nABCD_bootstrap <- function(x1, x2,
  B = 2000, conf = 0.95) {
  obs <- compute_nABCD(x1, x2)
  boot_vals <- replicate(B, {
    b1 <- sample(x1, replace = TRUE)
    b2 <- sample(x2, replace = TRUE)
    compute_nABCD(b1, b2)
  })
  alpha <- 1 - conf
  ci <- quantile(boot_vals,
    c(alpha/2, 1 - alpha/2), na.rm = TRUE)
  list(estimate = obs,
    ci_lower = ci[1], ci_upper = ci[2])
}
```

参考文献

- Andrews DWK (2000) “Inconsistency of the Bootstrap when a Parameter is on the Boundary of the Parameter Space” *Econometrica* 68(2): 399–405. DOI: [10.1111/1468-0262.00114](https://doi.org/10.1111/1468-0262.00114)
- Armstrong TB, Kolesár M (2021) “Finite-Sample Optimal Estimation and Inference on

- Average Treatment Effects Under Unconfoundedness” *Econometrica* 89(3): 1141–1177. DOI: [10.3982/ECTA16907](https://doi.org/10.3982/ECTA16907)
- Austin PC (2011) “An Introduction to Propensity Score Methods for Reducing the Effects of Confounding in Observational Studies” *Multivariate Behav Res* 46(3): 399–424. DOI: [10.1080/00273171.2011.568786](https://doi.org/10.1080/00273171.2011.568786)
 - Bareinboim E, Pearl J (2016) “Causal Inference and the Data-Fusion Problem” *Proc Natl Acad Sci USA* 113(27): 7345–7352. DOI: [10.1073/pnas.1510507113](https://doi.org/10.1073/pnas.1510507113)
 - Chen J, Quan H, Binkowitz B, Ouyang SP, Tanaka Y, Li G, Menjoge S, Ibia E (2010) “Assessing Consistent Treatment Effect in a Multi-Regional Clinical Trial: A Systematic Review” *Pharm Stat* 9(3): 242–253. DOI: [10.1002/pst.438](https://doi.org/10.1002/pst.438)
 - del Barrio E, Giné E, Matrán C (1999) “Central Limit Theorems for the Wasserstein Distance Between the Empirical and the True Distributions” *Ann Probab* 27(2): 1009–1071. DOI: [10.1214/aop/1022677394](https://doi.org/10.1214/aop/1022677394)
 - Emberson J, Lees KR, Lyden P, et al. (2014) “Effect of Treatment Delay, Age, and Stroke Severity on the Effects of Intravenous Thrombolysis with Alteplase for Acute Ischaemic Stroke: A Meta-Analysis of Individual Patient Data from Randomised Trials” *Lancet* 384(9958): 1929–1935. DOI: [10.1016/S0140-6736\(14\)60584-5](https://doi.org/10.1016/S0140-6736(14)60584-5)
 - Gibbs AL, Su FE (2002) “On Choosing and Bounding Probability Metrics” *Int Stat Rev* 70(3): 419–435. DOI: [10.1111/j.1751-5823.2002.tb00178.x](https://doi.org/10.1111/j.1751-5823.2002.tb00178.x)
 - ICH E17 Expert Working Group (2017) “General Principles for Planning and Design of Multi-Regional Clinical Trials (E17)” International Council for Harmonisation, Geneva, Switzerland.
 - IST-3 collaborative group (2012) “The Benefits and Harms of Intravenous Thrombolysis with Recombinant Tissue Plasminogen Activator Within 6 h of Acute Ischaemic Stroke (IST-3): A Randomised Controlled Trial” *Lancet* 379(9834): 2352–2363. DOI: [10.1016/S0140-6736\(12\)60768-5](https://doi.org/10.1016/S0140-6736(12)60768-5)
 - Long M, Wu H, Liu X, Chen J (2025) “Basic Considerations for the Consistency Evaluation Based on ICH E17 Guideline” *Ther Innov Regul Sci* 59(2): 328–336. DOI: [10.1007/s43441-024-00737-z](https://doi.org/10.1007/s43441-024-00737-z)
 - Panaretos VM, Zemel Y (2019) “Statistical Aspects of Wasserstein Distances” *Annu Rev Stat Appl* 6: 405–431. DOI: [10.1146/annurev-statistics-030718-104938](https://doi.org/10.1146/annurev-statistics-030718-104938)
 - Pearl J, Bareinboim E (2011) “Transportability of Causal and Statistical Relations: A Formal Approach” *Proc AAAI Conf Artif Intell* 25: 247–254.
 - Quan H, Li M, Chen J, Gallo P, Binkowitz B, Ibia E, Tanaka Y, Ouyang SP, Luo X, Li G, Menjoge S, Talerico S, Ikeda K (2010) “Assessment of Consistency of Treatment Effects in Multiregional Clinical Trials” *Drug Inf J* 44(5): 617–632. DOI: [10.1177/009286151004400515](https://doi.org/10.1177/009286151004400515)
 - Rousseeuw PJ, Croux C (1993) “Alternatives to the Median Absolute Deviation” *J Am Stat Assoc* 88(424): 1273–1283. DOI: [10.1080/01621459.1993.10476408](https://doi.org/10.1080/01621459.1993.10476408)
 - Sommerfeld M, Munk A (2018) “Inference for Empirical Wasserstein Distances on Finite

- Spaces” *J R Stat Soc Series B* 80(1): 219–238. DOI: [10.1111/rssb.12236](https://doi.org/10.1111/rssb.12236)
- Song J, Ji C, Chen M, Luo X, Quan H, Chen J (2025) “Basic Considerations for Data Pooling Strategy in Multi-Regional Clinical Trials (MRCs)” *Ther Innov Regul Sci* 59(2): 359–364. DOI: [10.1007/s43441-025-00744-8](https://doi.org/10.1007/s43441-025-00744-8)
 - Villani C (2009) *Optimal Transport: Old and New* Springer. DOI: [10.1007/978-3-540-71050-9](https://doi.org/10.1007/978-3-540-71050-9)
 - Wasserstein RL, Lazar NA (2016) “The ASA Statement on p-Values: Context, Process, and Purpose” *Am Stat* 70(2): 129–133. DOI: [10.1080/00031305.2016.1154108](https://doi.org/10.1080/00031305.2016.1154108)